

LAPORAN UJIAN TENGAH SEMETER
PREDIKSI MODERN DAN *MACHINE LEARNING*



Oleh:

NAMA MAHASISWA	NIM MAHASISWA	ROMBEL
Ikkhil Ghina Nabila	2404220008	1

Dosen Pengampu:

Nur Achmey Selgi Harwanti, S.Stat., M.Stat.

Prof. Dr. Ts. Ahmad Zia Ul-Saufie Bin Mohamad Japeri

PRODI SARJANA STATISTIKA DAN SAINS DATA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS NEGERI SEMARANG

2026

A. Ringkasan Data dan Prosedur Evaluasi

Dataset yang digunakan adalah *Default of Credit Card Clients* (Kaggle/UCI) dengan target `default.payment.next.month`. Ringkasan pemeriksaan data dan keputusan preprocessing:

- **Dimensi:** 30.000 observasi dan 25 kolom (23 predictor setelah ID dan target dikeluarkan). Tidak ada missing value dan tidak ada data duplikat.
- **Target:** 77,88% tidak default (0) dan 22,12% default (1), sehingga data cukup tidak seimbang. Karena itu split dan CV dilakukan secara stratified.
- **Nilai tidak wajar:** EDUCATION bernilai 0, 5, 6 (345 observasi) digabung ke kategori 4 (others); MARRIAGE bernilai 0 (54 observasi) digabung ke kategori 3 (others). Nilai PAY_x -2/-1/0 adalah kode valid, BILL_AMT negatif wajar (kelebihan bayar), dan outlier nominal tidak dihapus karena bukan kesalahan input.
- **Split dan CV:** train-test split 80:20 stratified (24.000 data latih, 6.000 data uji, `random_state = 42`), lalu 5-fold Stratified CV pada data latih. Seluruh preprocessing (scaling, encoding, cleaning) berada di dalam Pipeline sehingga tidak terjadi data leakage.
- **Metrik:** F1-score sebagai metrik utama; Accuracy, Precision, dan Recall sebagai metrik pendukung. Pemilihan model memakai CV F1, sedangkan test set hanya untuk konfirmasi.

1. Summary of Experiment Results

Tabel 1. Ringkasan hasil seluruh eksperimen (sesuai *output notebook*)

Exp	Model	CV F1	Test Accuracy	Test Precision	Test Recall	Test F1
1	Logistic Regression - Baseline	0,3525	0,8037	0,6630	0,2283	0,3397
2	Logistic Regression + Preprocessing	0,3641	0,8088	0,6923	0,2442	0,3610
3	Logistic Regression	0,3641	0,8088	0,6923	0,2442	0,3610
3	Decision Tree	0,3959	0,7232	0,3837	0,4152	0,3988
3	Random Forest	0,4737	0,8113	0,6298	0,3564	0,4552
4	Random Forest - Tuned	0,5441	0,7882	0,5197	0,5576	0,5380
5	Gradient Boosting	0,4794	0,8185	0,6662	0,3595	0,4670
5	AdaBoost	0,4499	0,8165	0,6717	0,3331	0,4453

Exp	Model	CV F1	Test Accuracy	Test Precision	Test Recall	Test F1
5	XGBoost	0,4676	0,8110	0,6271	0,3587	0,4564

Baris yang di-highlight adalah model final. Experiment 5 menguji tiga metode; Gradient Boosting terbaik di antara ketiganya berdasarkan CV F1. Experiment 3 menampilkan ketiga model yang dibandingkan.

Tabel 2. Ablation preprocessing pada Logistic Regression (Experiment 2)

Varian	CV F1	Accuracy	Precision	Recall	Test F1
Exp 1: Baseline (data mentah)	0,3525	0,8037	0,6630	0,2283	0,3397
A: Scaling + OHE	0,3659	0,8087	0,6908	0,2442	0,3608
B: A + cleaning kategori (dipakai di Exp 2)	0,3641	0,8088	0,6923	0,2442	0,3610
C: B + class_weight balanced (pembanding)	0,4812	0,6787	0,3679	0,6307	0,4647

Varian C bukan preprocessing murni (penanganan imbalance), sehingga hanya dilaporkan sebagai pembanding.

Tabel 3. Hyperparameter tuning Random Forest (Experiment 4): sebelum vs sesudah

Metrik	Sebelum tuning	Sesudah tuning	Selisih
CV F1	0,4737	0,5441	+0,0703
Test Accuracy	0,8113	0,7882	-0,0232
Test Precision	0,6298	0,5197	-0,1102
Test Recall	0,3564	0,5576	+0,2012
Test F1	0,4552	0,5380	+0,0827

Hyperparameter yang diuji (GridSearchCV, 5-fold, scoring F1): class_weight [None, balanced] dengan n_estimators = 100, max_depth = 10, min_samples_leaf = 1, max_features = sqrt. Kombinasi terbaik: class_weight = balanced, max_depth = 10, max_features = sqrt, min_samples_leaf = 1, n_estimators = 100 (best CV F1 = 0,5441).

2. Experimental Analysis

Pertanyaan 1 - Preprocessing

Ya, tetapi peningkatannya kecil. Dibanding baseline, CV F1 naik dari 0,3525 menjadi 0,3641 (+0,0117) dan Test F1 naik dari 0,3397 menjadi 0,3610 (+0,0213). Metrik lain juga naik: Accuracy 0,8037 menjadi 0,8088, Precision 0,6630 menjadi 0,6923, dan Recall 0,2283 menjadi 0,2442. Namun kenaikan CV F1 masih lebih kecil daripada standar deviasi CV baseline (0,0299), sehingga dampaknya tergolong modest. Hasil ablation menunjukkan scaling dan encoding menjadi sumber utama kenaikan, sedangkan cleaning kategori nyaris tidak berpengaruh (CV F1 0,3659 menjadi 0,3641). Recall tetap rendah (sekitar 0,24) karena ketidakseimbangan kelas belum ditangani; varian pembanding dengan `class_weight balanced` menaikkan CV F1 menjadi 0,4812 dan Recall menjadi 0,6307, dengan konsekuensi Precision turun menjadi 0,3679.

Pertanyaan 2 - Model Comparison

Random Forest. Random Forest memperoleh CV F1 tertinggi (0,4737) dibanding Decision Tree (0,3959) dan Logistic Regression (0,3641), dan hasil ini konsisten di test set: Test F1 0,4552 berbanding 0,3988 dan 0,3610. Random Forest juga menjaga keseimbangan metrik (Accuracy 0,8113, Precision 0,6298, Recall 0,3564). Decision Tree memiliki Recall lebih tinggi daripada Logistic Regression dan Random Forest (0,4152) tetapi Precision-nya rendah (0,3837) dan Accuracy-nya terendah (0,7232), indikasi overfitting pada pohon tanpa pembatasan kedalaman. Logistic Regression memiliki Precision tertinggi (0,6923) namun Recall paling rendah (0,2442). Karena F1 adalah metrik utama, Random Forest dipilih untuk Experiment 4.

Pertanyaan 3 - Hyperparameter Tuning

Ya, tuning meningkatkan F1. CV F1 naik dari 0,4737 menjadi 0,5441 (+0,0703) dan Test F1 naik dari 0,4552 menjadi 0,5380 (+0,0827); keduanya searah. Peningkatan terutama berasal dari Recall yang naik dari 0,3564 menjadi 0,5576, sementara Precision turun dari 0,6298 menjadi 0,5197 dan Accuracy turun dari 0,8113 menjadi 0,7882. Perlu dicatat bahwa pada grid yang dipakai hanya `class_weight` yang bervariasi; kombinasi dengan `class_weight = None` hanya mencapai CV F1 0,4715, sedangkan `balanced` mencapai 0,5441. Jadi kenaikan F1 bersumber dari penanganan imbalance (model lebih berani memprediksi kelas default), bukan dari pengaturan kompleksitas pohon.

Pertanyaan 4 - Advanced Model

Tidak. Dari tiga metode advanced, Gradient Boosting terbaik (CV F1 0,4794; Test F1 0,4670), diikuti XGBoost (0,4676; 0,4564) dan AdaBoost (0,4499; 0,4453). Dibanding model terbaik

Experiment 4 (Random Forest tuned: CV F1 0,5441; Test F1 0,5380), selisih Gradient Boosting adalah -0,0647 pada CV F1 dan -0,0710 pada Test F1, jauh melampaui standar deviasi CV Gradient Boosting (0,0075). Gradient Boosting unggul pada Accuracy (0,8185 vs 0,7882) dan Precision (0,6662 vs 0,5197), tetapi Recall-nya hanya 0,3595 sehingga F1 lebih rendah. Dibanding Random Forest sebelum tuning, Gradient Boosting hanya sedikit lebih baik (CV F1 0,4794 vs 0,4737), selisih yang kecil. Model yang lebih kompleks tidak otomatis lebih baik ketika masalah imbalance tidak ditangani.

Pertanyaan 5 - Final Model

Model final: Random Forest hasil tuning (class_weight = balanced, n_estimators = 100, max_depth = 10, max_features = sqrt, min_samples_leaf = 1). Model ini memiliki CV F1 tertinggi (0,5441) dan Test F1 tertinggi (0,5380) di antara seluruh model, dengan Accuracy 0,7882, Precision 0,5197, dan Recall 0,5576. Alasan lengkap dijelaskan pada bagian 4 dan 5 di bawah.

3. Kesimpulan

Performa naik bertahap dari baseline (Test F1 0,3397) ke preprocessing (0,3610), Random Forest (0,4552), dan Random Forest hasil tuning (0,5380). Preprocessing standar memberi dampak kecil; lompatan terbesar datang dari model non-linear (Random Forest) dan dari penanganan ketidakseimbangan kelas lewat class_weight, yang menaikkan Recall secara nyata. Model advanced (Gradient Boosting, AdaBoost, XGBoost) pada pengaturan default tidak mengungguli Random Forest tuned. Keterbatasan: Recall masih sekitar 0,56, grid tuning terbatas pada class_weight, dan evaluasi memakai satu pembagian train-test. Pengembangan lanjutan dapat berupa tuning threshold keputusan, SMOTE, tuning model boosting dengan penanganan imbalance, dan feature engineering dari riwayat pembayaran.

4. Model Final yang Dipilih

Aspek	Nilai	Keterangan
Model	Random Forest (tuned)	class_weight balanced
CV F1	0,5441	Tertinggi dari semua model
Test F1	0,5380	Tertinggi dari semua model
Test Accuracy	0,7882	Metrik pendukung
Test Precision	0,5197	Metrik pendukung
Test Recall	0,5576	Metrik pendukung

5. Alasan Pemilihan Model Final

- **F1 tertinggi dan konsisten.** Model unggul pada CV F1 (0,5441) maupun Test F1 (0,5380), sehingga pemilihan tidak bergantung pada satu pembagian data.
- **Recall hampir dua kali lipat baseline.** Recall 0,5576 berbanding 0,2283 pada baseline, artinya jauh lebih banyak nasabah yang benar-benar default berhasil terdeteksi, yang penting dalam konteks manajemen risiko kredit.
- **Precision dan Recall seimbang.** Precision 0,5197 dan Recall 0,5576 berdekatan, berbeda dengan model lain yang berat sebelah (mis. Gradient Boosting Precision 0,6662 tetapi Recall 0,3595).
- **Accuracy yang lebih rendah dapat diterima.** Accuracy 0,7882 lebih rendah daripada Gradient Boosting (0,8185), tetapi Accuracy menyesatkan pada data dengan 77,88% kelas mayoritas; menebak semua nasabah tidak default saja sudah menghasilkan Accuracy sekitar 0,78. Karena F1 ditetapkan sebagai metrik utama, trade-off ini sesuai tujuan.
- **Tidak memilih model paling kompleks.** Keputusan didasarkan pada hasil evaluasi: model boosting yang lebih kompleks justru memiliki F1 lebih rendah (maksimum 0,4670).

Lampiran



UCI_Credit_Card.csv



uts_pmml_22042200
08.ipynb